


Consommation énergétique des bâtiments

2026



Mission et objectifs

ANALYSE EXPLORATOIRE


Faire ressortir des indicateurs clés sur les différents bâtiments de la ville pour essayer de déterminer les principaux vecteurs de consommation.

PRÉDICTION

Préparation du jeu de données, et entraînement de plusieurs modèles de prédiction de la consommation énergétique des bâtiments.


CONCLUSION

Comparaison des différents modèles, optimisation, analyse des indicateurs clés dans la prédiction de la consommation.



Hypothèses

- Plus un bâtiment est grand, plus il va consommer
- Plus la taille du parking d'un site est grande, plus la consommation est élevée
- Plus le score énergétique est faible, plus la consommation est grande (pertes thermiques)
- Plus un bâtiment est ancien, plus il consomme (ancienne norme ou vieux matériaux de construction)
- Le type de bâtiment influe sur sa consommation
- Le quartier influe sur la consommation (zones commerciales ou industrielles)
- Plus un site possède de bâtiments, plus elle consomme
- Un site qui contient plus de parking que de bâtiments, consomme moins



Jeu de données

PROVENANCE

Jeu de données issue du site de la ville de Seattle.
https://data.seattle.gov/Built-Environment/Building-Energy-Benchmarking-Data-2015-Present/teqw-tu6e/about_data

CONTENU

Fichier CSV unique avec 3376 entrées et 46 colonnes de données. Chaque ligne représente un site de la ville de Seattle qui peut contenir plusieurs bâtiments et parkings




ANNÉE DES DONNÉES

Les données des bâtiments sont celles pour l'année 2016, il n'y a aucune donnée concernant d'autres années.



DÉTAIL DES COLONNES

Adresse, type de bâtiment, année de construction, nombre d'étage, usage principal, score énergétique, consommation (gaz, vapeur et électricité) etc ...


Analyse exploratoire 1/3



Analyse exploratoire 2/3



Analyse exploratoire 3/3



Conclusions :

- La surface totale, la surface du parking, la surface du bâtiment, le nombre de d'usages et le secteur d'activité principal ont une influence sur la consommation totale.
- Le quartier, dans une moindre mesure, a une influence sur la consommation
- La consommation a une influence sur les émissions de gaz à effet de serre
- Le type principal d'approvisionnement en énergie influe sur les émissions de gaz à effet de serre
- Le score énergétique et la consommation ne sont pas liés, en revanche le score énergétique dépend du type principal d'énergie du site.

Préparation des données

BÂTIMENTS RÉSIDENTIELS

Retrait de l'ensemble des sites résidentiels du jeu de donnée qui ne sont pas le sujet de l'étude

INCOHÉRENCE DE CONSOMMATION


Retrait des sites qui ont un écart de plus de 1% entre consommation total et consommation gaz + vapeur + électricité

COLONNES INUTILES

Suppression de beaucoup de colonnes vides, non utiles, ou contenant toutes la même valeur
ex : city qui contient Seattle pour tous les sites

Features

- Ratio taille du parking – Taille totale du site
- Ratio taille du bâtiment – Taille totale du site
- Nombre d'activités d'un site
- Ratio surface de l'usage principal – Taille totale du site
- Empreinte au sol
- Ratio nombre d'activités – Taille totale du site



Jeu d'entraînement

DATA LEAKAGE

Retrait des colonnes de consommation totale, consommation gaz, électrique, vapeur, score énergétique, émission de gaz à effet de serre

ENCODAGE

Encodage onehot des colonnes catégorielles restantes, et écrasement logarithmique des indicateur de surface

DÉCOUPAGE

Découpage du jeu de données restant en 80% de données d'entraînement pour 20% de données de test

Prédiction

Modèles utilisés :

https://scikit-learn.org/stable/machine_learning_map.html

- Régression Linéaire (modèle étalon)
- RandomForest
- GradientBoosting
- Lasso
- SVR

MODÈLE


VALIDATION CROISÉE

LES MÉTRIQUES DE PERFORMANCE
(MAE, RMSE)

CONTRÔLE ET VISUALISATION

Résultats

	LinearRegression	RandomForest	GradientBoosting	Lasso	SVR
MAE (kBtu)	3,461,718	3,219,914	2,912,722	5,063,024	3,614,697
RMSE (kBtu)	7,256,550	6,609,262	5,857,380	12,441,991	6,999,802








Optimisation

Phase d'optimisation du modèle GradientBoosting ayant donné les meilleurs résultats.

L'utilisation de GridSearchCV nous donne un modèle qui se trompe de : **3,104,563 kBTu** après optimisation



Importance des features




Conclusion

L'enveloppe physique d'un bâtiment ne suffit pas à expliquer toute sa consommation

- Manque de donnée d'utilisation des bâtiments
 - Nombre de personnes qui y travaillent, horaires d'ouverture
 - Présence de panneaux solaires, climatisation, type d'usage plus détaillés
 - Travaux de rénovation

Piste d'amélioration :

- Croiser notre jeu de données avec d'autres jeux de données
- Tester une approche différente, avec un modèle par type de bâtiment par exemple.



Merci

DES QUESTIONS ?

